

Глубокий разбор: Кросс-валидация и чистота эксперимента

Твой персональный гид по ML

4 мая 2026 г.

Введение

Ниже представлен подробный разбор методов кросс-валидации и проблем оценки качества моделей, составленный на основе предоставленных материалов.

Содержание

1	Что такое кросс-валидация?	2
2	Метод Hold-out	2
3	Стратификация (Stratification)	2
4	k-Fold кросс-валидация	2
5	Leave-one-out (LOO)	2
6	Stratified k-Fold	3
7	Когда стоит заподозрить, что оценка качества завышена?	3
8	Примеры «подмешивания» тестовых данных (Data Leakage)	4

1 Что такое кросс-валидация?

Кросс-валидация — это процедура оценки качества модели, которая позволяет получить надежную оценку того, как алгоритм будет работать на новых, ранее не виденных данных. Она критически важна для сравнения моделей и подбора гиперпараметров.

2 Метод Hold-out

Самый простой и быстрый способ. Мы делим данные на две части:

- **Train (обучающая)**: на ней модель учится.
- **Test (тестовая/отложенная)**: на ней мы измеряем качество.

Обычно используется пропорция **70/30** или **80/20**.

Минус: Оценка сильно зависит от того, *какие именно* объекты попали в тест. Если в тест случайно попали «легкие» объекты, метрика будет завышена.

3 Стратификация (Stratification)

Это техника, гарантирующая, что **распределение классов** (или других важных признаков) в тренировочной и тестовой выборках будет одинаковым.

Зачем это нужно? Если у вас в данных 95% здоровых пациентов и 5% больных, при обычном случайном делении в тест могут вообще не попасть больные люди. Модель покажет 100% точность, просто предсказывая «здоров», но на деле она бесполезна.

Решение: Стратификация «нарезает» данные так, чтобы и в трейне, и в тесте сохранились те же 5% больных.

4 k-Fold кросс-валидация

Это «золотой стандарт» оценки.

1. Весь датасет разбивается на k равных частей (фолдов), обычно $k = 5$ или $k = 10$.
2. Модель обучается k раз.
3. На каждой итерации один фолд становится тестовым, а остальные $k - 1$ — тренировочными.
4. Итоговая метрика — это **среднее арифметическое** результатов всех k итераций.

5 Leave-one-out (LOO)

Экстремальный случай k-Fold, где k равно количеству объектов в выборке (N).

- **Как это работает:** Мы обучаемся на всех объектах, кроме одного, и на этом одном тестируемся. И так N раз.
- **Плюс:** Мы используем максимум данных для обучения.
- **Минус:** Это невероятно долго и дорого в плане вычислений (если у вас миллион объектов, придется обучить модель миллион раз).




Рис. 1: Визуализация процесса стратификации.

6 Stratified k-Fold

Это комбинация двух методов: данные разбиваются на k фолдов, но при этом в каждом фолде соблюдается **стратификация**. Это самый надежный способ оценки для задач классификации, особенно когда один класс встречается реже другого.

7 Когда стоит заподозрить, что оценка качества завышена?

Если вы видите метрику **0.999** или резкий скачок качества по сравнению с бейслайном, не спешите открывать шампанское. Скорее всего, произошел **Overfitting** или **Data Leakage**.

Красные флаги:

1. Метрика на тесте почти такая же идеальная, как на трейне (для сложных задач это редкость).
2. Модель отлично работает на кросс-валидации, но «разваливается» на новых реальных данных.
3. В данных есть признак, который подозрительно сильно коррелирует с таргетом (возможно, это таргет в другом обличии).

К-КРАТНАЯ КРОСС-ВАЛИДАЦИЯ (5 фолдов)




Рис. 2: Схема k-Fold кросс-валидации.

8 Примеры «подмешивания» тестовых данных (Data Leakage)

Это ситуация, когда информация из будущего или из теста просачивается в обучение. Модель «подсматривает» правильные ответы.

Примеры:

- **Масштабирование (Scaling) до разбиения:** Вы посчитали среднее и дисперсию по *всему* датасету, а потом применили `StandardScaler`. Модель уже «знает» среднее значение тестовой выборки. **Правильно:** считать параметры только на трейне.
- **Временные ряды (Time Series):** Вы предсказываете курс акций сегодня, используя данные за завтра. В кросс-валидации временных рядов тест всегда должен быть позже трейна.
- **Дубликаты:** Если в данных есть дублирующие строки, один и тот же объект может попасть и в трейн, и в тест. Модель просто «вспомнит» ответ.
- **Косвенные признаки:** Например, предсказание вероятности рака, используя признак «прошел ли пациент химиотерапию». Терапия назначается *после* диагноза, поэтому она содержит ответ в себе.



Рис. 3: Схематичное представление утечки данных.

Помни, кросс-валидация — это твой страховой полис. Лучше потратить время на обучение 5 фолдов сейчас, чем через месяц объяснять заказчику, почему «идеальная» модель на практике выдает случайные числа.

Antigravity: Всегда используй пайплайны. Это защитит тебя от 90% случаев утечки данных через предобработку.