

Глубокий разбор: Теория решающих деревьев

Твой персональный гид по ML

4 мая 2026 г.

Введение

Ниже представлен углубленный разбор теории решающих деревьев, подготовленный на основе предоставленных материалов (Яндекс Хендбук).

Содержание

1	Фундаментальные свойства решающих деревьев	2
2	Жадный алгоритм построения	3
3	Критерии ветвления и информативность	3
4	Работа с особенностями данных	3
5	Регуляризация	3
6	Алгоритмические оптимизации (Трюки)	4

1 Фундаментальные свойства решающих деревьев

- **Вопрос:** Почему функция дерева является кусочно-постоянной и как это влияет на оптимизацию?
- **Ответ:** Решающее дерево разбивает признаковое пространство на непересекающиеся гиперпрямоугольники (листья). В каждом листе модель предсказывает одно и то же значение (среднее или моду). Математически это сумма индикаторных функций: $a(x) = \sum_{j=1}^J c_j[x \in L_j]$. Так как эта функция разрывна, а её производная по параметрам разбиения (порогам) почти везде равна нулю или не существует, **градиентные методы** нельзя использовать для построения структуры самого дерева.
- **Вопрос:** Почему дерево не умеет экстраполировать?
- **Ответ:** В отличие от линейных моделей, которые могут бесконечно продолжать прямую линию, дерево «заперто» в значениях обучающей выборки. Если новый объект имеет значения признаков далеко за пределами тренировочных, он все равно попадет в один из крайних листьев и получит константное предсказание этого листа.




Рис. 1: Разбиение признакового пространства на гиперпрямоугольники (листья).

Дерево — это отличный интерполятор, но плохой предсказатель «будущих рекордов». Оно никогда не предскажет цену квартиры выше, чем та, что была в обучении.

2 Жадный алгоритм построения

- **Вопрос:** Почему построение оптимального дерева — NP-трудная задача и в чем суть «жадности»?
- **Ответ:** Количество возможных структур дерева растет комбинаторно. Чтобы найти глобально оптимальное дерево, нужно было бы перебрать все возможные последовательности разбиений, что невозможно. **Жадный алгоритм** на каждом шаге ищет один лучший сплит (признак и порог), который максимально уменьшает ошибку прямо сейчас, не заглядывая в будущее.

Жадность — это как выбор самого вкусного куска торта прямо сейчас вместо того, чтобы сесть на диету ради здоровья в будущем. Это работает быстро, но не гарантирует идеальный результат для всей структуры.

3 Критерии ветвления и информативность

- **Gain (Прирост информативности):** $G = I(\text{parent}) - \frac{N_{\text{left}}}{N}I(\text{left}) - \frac{N_{\text{right}}}{N}I(\text{right})$. Мы хотим, чтобы неопределенность (I) в дочерних вершинах была минимальной.
- **MSE (для регрессии):** Это просто дисперсия таргетов в узле. Минимизируя её, мы делаем объекты в листе максимально похожими на их среднее.
- **Энтропия Шеннона:** $-\sum p_i \log p_i$. Максимальна, когда классы перемешаны 50/50, и равна нулю, когда в узле только один класс.
- **Критерий Джини:** $1 - \sum p_i^2$. Это вероятность ошибки, если мы будем предсказывать классы объектов случайно.

Критерий доли ошибок плох тем, что он «грубый» — он может не измениться после сплита, даже если классы стали более разделенными.

4 Работа с особенностями данных

- **Категории:** Помимо ONE, в деревьях можно использовать группировку категорий. Категории сортируют по среднему значению таргета и ищут порог так же, как в числовом признаке.
- **Пропуски:**
 1. Можно отправлять пропущенные значения в ту сторону, где ошибка меньше.
 2. **Суррогатные сплиты:** Если основной признак пропущен, дерево использует «запасной» признак, который сильнее всего коррелирует с основным.

5 Регуляризация

- **Max depth:** Глубина дерева.
- **Min samples leaf:** Минимум объектов в листе.
- **Max leaf nodes:** Ограничение на количество ответов модели.
- **Min impurity decrease:** Не делать сплит, если улучшение незначительно.

6 Алгоритмические оптимизации (Трюки)

- **Сортировка** ($O(N \log N)$): Позволяет обновлять статистики за $O(1)$ при переборе порогов.
- **Гистограммный метод**: Разбиение признаков на "корзины" (биннинг). Это на порядки ускоряет обучение и экономит память.

Antigravity: Гистограммный метод — это "секретный соус" современных библиотек (LightGBM, CatBoost), позволяющий обучать деревья на миллионах строк за секунды.