

Глубокий разбор: Метрические методы обучения

Твой персональный гид по ML

4 мая 2026 г.

Введение

Ниже представлен детальный разбор метрических методов обучения, подготовленный на основе материалов курса по машинному обучению (Яндекс Хендбук).

Содержание

1	Алгоритм k-ближайших соседей (k-NN)	2
2	Метрики и функции расстояния	2
3	Модификации: Взвешенный k-NN	2
4	Ядерная регрессия (Формула Надарая-Ватсона)	3
5	Оптимизация поиска ближайших соседей	3

1 Алгоритм k-ближайших соседей (k-NN)

- **Математическая формулировка:** Пусть задана обучающая выборка $X = \{(x_i, y_i)\}$. Для нового объекта x мы находим k ближайших к нему объектов из X : $x_{(1)}, \dots, x_{(k)}$.
- **Классификация:** Ответ — наиболее часто встречающийся класс среди соседей (мода): $a(x) = \operatorname{argmax}_{y \in Y} \sum_{j=1}^k [y_{(j)} = y]$.
- **Регрессия:** Ответ — среднее арифметическое ответов соседей: $a(x) = \frac{1}{k} \sum_{j=1}^k y_{(j)}$.
- **Параметр k :**
 - При малых k модель имеет **низкое смещение (bias)**, но **высокий разброс (variance)**.
 - При больших k модель имеет **высокое смещение**, но **низкий разброс**.

Выбор k — это классический поиск компромисса между недообучением и переобучением. Обычно k подбирают на кросс-валидации.

2 Метрики и функции расстояния

- **Метрики Минковского (L_p):** $\rho(x, z) = \left(\sum_{i=1}^d |x_i - z_i|^p \right)^{1/p}$.
 - L_1 (Манхэттенское): сумма модулей разностей. Менее чувствительна к выбросам.
 - L_2 (Евклидово): стандартное расстояние по прямой.
- **Косинусное сходство:** $\cos(\theta) = \frac{\langle x, z \rangle}{\|x\| \|z\|}$. Расстояние определяется как $1 - \cos(\theta)$. Измеряет угол между векторами, игнорируя их длину.
- **Расстояние Жаккара:** $1 - \frac{|A \cap B|}{|A \cup B|}$. Используется для сравнения множеств (стандарт для бинарных признаков).

*Помните, что перед использованием L_p метрик данные **обязательно** нужно масштабировать, иначе признак с большим диапазоном значений «поглотит» все остальные.*

3 Модификации: Взвешенный k-NN

- **Веса по рангу:** Вес j -го соседа зависит от его номера: $w_j = \frac{k+1-j}{k}$.
- **Веса от расстояния:** $w_i = f(\rho(x, x_i))$. Позволяет доверять более близким объектам сильнее.
- **Ядерное сглаживание:** Вес задается через ядро K : $w_i = K\left(\frac{\rho(x, x_i)}{h}\right)$.

4 Ядерная регрессия (Формула Надарая-Ватсона)

- **Принцип:** Это обобщение k-NN, где предсказание — это взвешенное среднее ответов всех объектов обучающей выборки:
$$a(x) = \frac{\sum_{i=1}^n y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^n K\left(\frac{\rho(x, x_i)}{h}\right)}.$$
- **Ширина окна h :**
 - Малое h : веса быстро затухают (риск переобучения).
 - Большое h : прогноз становится слишком гладким (риск недообучения).

5 Оптимизация поиска ближайших соседей

- **k-d деревья:** Бинарное дерево, разбивающее пространство вдоль осей. Эффективно при $d < 20$.
- **Приближенные методы (ANN):** Согласие найти "достаточно близкого" соседа для ускорения в тысячи раз.
- **Random Projection Trees:** Используют случайные проекции (лемма Джонсона-Линденштраусса).

Antigravity: В реальном продакшене (Faiss, HNSW) почти всегда используются именно ANN, так как точный поиск на миллионах объектов невозможен.