

0.1 Офлайнные метрики

Офлайнные метрики вычисляются на исторических данных (тестовых выборках) без участия реальных пользователей.

- **Зачем нужны:**
 - Для быстрой итерации и сравнения моделей между собой.
 - Для отбора лучших кандидатов перед запуском дорогостоящих А/В-тестов.
 - Для отладки алгоритма и поиска его слабых мест (анализ ошибок).
- **Примеры:** Accuracy, Precision, Recall, ROC-AUC, RMSE, MAE.

0.2 Онлайнные метрики

Онлайнные метрики измеряются в реальном времени при взаимодействии системы с «живыми» пользователями в ходе А/В-тестирования.

- **Зачем нужны:**
 - Для оценки реального влияния модели на бизнес-показатели.
 - Для учета поведенческих факторов и внешних эффектов (например, сезонность или действия конкурентов).
 - Для проверки «прокси-гипотез» (коррелирует ли рост ROC-AUC с ростом выручки).
- **Примеры:** CTR (Click-Through Rate), Конверсия (CR), ARPU (Average Revenue Per User), время сессии, Retention.

0.3 Ключевые отличия

Характеристика	Офлайн	Онлайн
Источник данных	Исторические данные	Реальные пользователи
Скорость получения	Минуты/часы	Дни/недели
Стоимость	Дешево (CPU/GPU)	Дорого (риск потери прибыли)
Объективность	Оценивает модель	Оценивает продукт/бизнес

Главная проблема ML в продакшене — отсутствие корреляции между офлайн и онлайн метриками. Модель может идеально предсказывать вероятность клика (высокий ROC-AUC), но показывать плохой CTR из-за того, что предлагаемые товары неинтересны пользователям в данный момент.

1 Функция потерь vs Метрика качества

Часто новички путают эти понятия, так как в некоторых задачах (например, в регрессии) они могут совпадать (MSE). Однако это концептуально разные вещи.

1.1 Функция потерь (Loss Function)

Это математический инструмент для **обучения** модели.

- **За что отвечает:** Показывает, насколько сильно модель «ошиблась» на конкретном объекте или выборке.
- **Как используется:** Минимизируется градиентными методами (SGD, Adam) для настройки весов.
- **Требования:** Должна быть **дифференцируемой** (или иметь субградиент), чтобы мы могли вычислить производную.
- **Примеры:** LogLoss, Cross-Entropy, Huber Loss.

1.2 Метрика качества (Metric)

Это инструмент для **оценки** модели человеком или бизнесом.

- **За что отвечает:** Показывает реальное качество работы модели в понятных единицах (проценты, рубли, количество ошибок).
- **Как используется:** Для принятия решения о запуске модели, сравнения алгоритмов, мониторинга.
- **Требования:** Должна быть **интерпретируемой**. Не обязана быть дифференцируемой.
- **Примеры:** Accuracy, F1-score, ROC-AUC.

1.3 В чем ключевые отличия?

1. **Цель:** Loss — для оптимизатора, Metric — для человека.
2. **Гладкость:** Функция потерь должна быть гладкой. Метрика может быть дискретной (например, Accuracy меняется скачками).
3. **Интерпретируемость:** Мы редко можем сказать, что означает «LogLoss = 0.23» в терминах бизнеса, но «Accuracy = 95%» понятно всем.

Почему нельзя просто минимизировать Accuracy? Потому что её производная везде равна нулю (или не существует), и градиентный спуск не сможет сдвинуть веса модели с места. Поэтому мы используем LogLoss как «дифференцируемый суррогат» для Accuracy.

2 Матрица ошибок (Confusion Matrix)

Матрица ошибок — это таблица, позволяющая визуализировать производительность алгоритма классификации.

	Y=1 (Positive)	Y=0 (Negative)
a(x)=1	TP (True Positive)	FP (False Positive)
a(x)=0	FN (False Negative)	TN (True Negative)

Таблица 2: Матрица ошибок для бинарной классификации.




Рис. 1: Компромисс между точностью и полнотой.

2.1 Основные метрики качества

На основе матрицы ошибок вычисляются базовые метрики:

- **Accuracy** (Доля правильных ответов): Показывает общую точность модели.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision** (Точность): Доля истинно положительных среди всех объектов, которые алгоритм отнес к положительному классу. Помогает минимизировать количество ложных срабатываний (FP).

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall** (Полнота): Доля истинно положительных среди всех объектов положительного класса. Помогает минимизировать количество пропусков (FN).

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-measure** (F-мера): Гармоническое среднее между точностью и полнотой. Позволяет оценить модель одним числом, когда важны и Precision, и Recall.

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

Precision и Recall часто находятся в противофазе: пытаясь улучшить одну метрику, мы обычно ухудшаем другую. Выбор баланса между ними зависит от цены ошибки (что хуже: ложная тревога или пропуск цели?).




Рис. 2: Сравнение ROC и PR кривых.

3 Кривые и площади: ROC-AUC и PR-AUC

Эти метрики оценивают качество ****ранжирования**** объектов моделью, а не просто точность предсказания классов при фиксированном пороге.

3.1 ROC-AUC (Receiver Operating Characteristic)

Кривая строится в осях:

- **TPR** (True Positive Rate / Recall): $\frac{TP}{TP+FN}$.
- **FPR** (False Positive Rate): $\frac{FP}{FP+TN}$.

Суть: Показывает долю пар объектов разного класса, которые алгоритм верно упорядочил (положительный объект имеет оценку выше отрицательного).

- **Плюсы:**
 - Не зависит от порога классификации.
 - Устойчива к изменению баланса классов (формулы TPR и FPR нормируются внутри своего класса).

- **Минусы:**
 - На сильно несбалансированных данных (например, 1:1000) может быть обманчиво высокой, даже если модель ошибается на большинстве реальных позитивных объектов.
- **Где подходит:** Задачи с более-менее сбалансированными классами.

3.2 PR-AUC (Precision-Recall Curve)

Кривая строится в осях:

- **Recall** (Полнота).
- **Precision** (Точность).
- **Плюсы:**
 - Явно фокусируется на качестве предсказания редкого (положительного) класса.
 - Очень чувствительна к ложным срабатываниям (FP), что критично для задач с дисбалансом.
- **Минусы:**
 - Сильно зависит от баланса классов в обучающей выборке. При изменении доли позитивных объектов кривая «просядет» или поднимется.
- **Где подходит:** Задачи с сильным дисбалансом (фрод, дефектоскопия, редкие заболевания).

Главное правило: если классы сбалансированы — смотри на ROC-AUC. Если есть сильный дисбаланс — PR-AUC даст гораздо более честную картину.

4 Сводная таблица метрик классификации

Метрика	Пример задачи	Где ЗАПРЕЩЕНО
Accuracy	Распознавание цифр	Фрод (сильный дисбаланс)
Precision	Таргетинг (высокая цена звонка)	Поиск пропавших (важен каждый сигнал)
Recall	Диагностика рака (нельзя пропустить)	Спам-фильтр (важные письма не в спам)
F1-measure	Поиск в базе знаний	Когда Recall критичнее Precision

5 Метрики регрессии

В задачах регрессии мы предсказываем вещественное число $\hat{y} \in \mathbb{R}$.

5.1 MSE (Mean Squared Error)

Среднеквадратичная ошибка.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Плюсы:** Хорошая «математика» (выпуклая, дифференцируемая), сильно штрафует за большие отклонения.
- **Минусы:** Неустойчива к выбросам (один выброс может «утянуть» значение метрики), трудно интерпретировать (единицы измерения в квадрате).

5.2 MAE (Mean Absolute Error)

Средняя абсолютная ошибка.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Плюсы:** Устойчива к выбросам (робастна), легко интерпретируется (единицы измерения совпадают с таргетом).
- **Минусы:** Не дифференцируема в нуле (сложнее использовать как Loss).




Рис. 3: Визуализация: MSE (слева) гораздо сильнее реагирует на выбросы, чем MAE (справа).

5.3 Относительные метрики: MAPE, SMAPE, WAPE

Используются, когда нам важна не абсолютная ошибка, а ошибка в процентах от величины таргета.

- **MAPE** (Mean Absolute Percentage Error):

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Плохо: нельзя использовать, если в данных есть нули ($y_i = 0$). Асимметрична: сильнее штрафует за занижение прогноза, чем за завышение.

- **SMAPE** (Symmetric MAPE):

$$SMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

Решает проблему деления на ноль (если $\hat{y}_i$ не ноль) и уменьшает асимметрию.

- **WAPE** (Weighted MAPE):

$$WAPE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|}$$

Позволяет избежать проблем с околонулевыми значениями отдельных объектов, суммируя ошибки по всей выборке.

5.4 RMSLE (Root Mean Squared Logarithmic Error)

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$$

- **Зачем:** Когда таргет меняется на порядки (цены на жилье, продажи). Штрафует за относительную ошибку, а не абсолютную.
- **Особенность:** Сильнее штрафует за ****занижение**** прогноза ($y > \hat{y}$), чем за завышение.

Antigravity: Метрики — это мост между бизнесом и математикой. Неверный выбор метрики ведет к созданию идеальной, но бесполезной модели.