

Мастер-разбор: Линейные модели в машинном обучении

Теория, доказательства и вопросы с собеседований

Твой персональный гид по ML

10 мая 2026 г.

Содержание

1	Типология задач машинного обучения	3
2	Математический аппарат и обозначения	3
2.1	Обозначения	3
2.2	Решение МНК (Ordinary Least Squares)	4
2.3	Численные методы: QR-разложение	4
2.4	Градиентный спуск (Gradient Descent)	4
3	Обработка категориальных признаков	4
3.1	One-Hot Encoding (OHE)	5
4	Интерпретируемость моделей	5
4.1	Линейные модели	5
4.2	Решающие деревья	6
5	Свойства и ограничения линейных моделей	6
5.1	Свойства	6
5.2	Ограничения	6
6	Сведение обучения к задаче оптимизации	6
6.1	Функция потерь и Функционал качества	7
6.2	Stochastic Gradient Descent (SGD) и Mini-batches	7
7	Регуляризация и борьба с мультиколлинеарностью	7
7.1	Мультиколлинеарность	7
7.2	L2-регуляризация (Ridge Regression)	7
7.3	L1-регуляризация (Lasso)	8
7.4	Сравнительная таблица	8
8	Логистическая регрессия	8
8.1	Сигмоида (σ)	8
8.2	Метод максимального правдоподобия (MLE)	8
8.3	Изменения пространства признаков	9

9	Функции потерь классификации	9
9.1	Perceptron Loss	9
9.2	Hinge Loss и SVM	9
10	Kernel Trick и ядерные методы	10
10.1	Суть метода	10
10.2	Виды ядер	10
10.3	Kernel Density Estimation (KDE)	10
11	Deep Q&A: Вопросы и подробные ответы	11

1 Типология задач машинного обучения

В обучении с учителем (*Supervised Learning*) мы выделяем следующие основные задачи:

- **Регрессия (Regression):** Целевая переменная $y \in \mathbb{R}$ является непрерывной. Мы ищем функциональную зависимость, которая минимизирует ошибку предсказания вещественного числа.
 - *Примеры:* Прогноз стоимости недвижимости на основе характеристик (площадь, район), предсказание температуры на завтра, оценка времени прибытия курьера (ETA).
 - *Метрики:* MSE, MAE, R^2 .
- **Бинарная классификация (Binary Classification):** $y \in \{0, 1\}$ (или $\{-1, 1\}$). Необходимо разделить объекты на две непересекающиеся группы. Модель обычно выдает вероятность $p \in [0, 1]$.
 - *Примеры:* Спам-фильтр (письмо спам или нет), кредитный скоринг (вернет ли клиент кредит), медицинская диагностика (наличие или отсутствие заболевания).
 - *Метрики:* Accuracy, Precision, Recall, F1-score, ROC-AUC.
- **Многоклассовая классификация (Multiclass Classification):** $y \in \{1, \dots, K\}$. Выбор одного из K взаимоисключающих классов.
 - *Примеры:* Распознавание рукописных цифр (0-9), классификация типов ирисов (Setosa, Versicolour, Virginica), определение языка текста.
 - *Подходы:* One-vs-Rest, One-vs-One, Softmax.
- **Ранжирование (Ranking):** Задача не в предсказании точного значения, а в восстановлении правильного **порядка** объектов.
 - *Примеры:* Выдача поисковой системы (релевантные ссылки выше), ранжирование товаров в ленте рекомендаций, сортировка кандидатов в системе подбора персонала.
 - *Метрики:* nDCG, MRR, Precision@k.

2 Математический аппарат и обозначения

2.1 Обозначения

Для формального описания линейных моделей введем следующие обозначения:

- $\mathbf{X} \in \mathbb{R}^{N \times D}$ — матрица «объекты-признаки», где N — число объектов, D — число признаков.
- $\mathbf{y} \in \mathbb{R}^N$ — вектор истинных ответов (таргетов).
- $\boldsymbol{\omega} \in \mathbb{R}^D$ — вектор параметров (весов) модели.
- Предсказание модели: $\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\omega}$.

2.2 Решение МНК (Ordinary Least Squares)

Мы минимизируем сумму квадратов ошибок:

$$Q(\omega) = \|\mathbf{X}\omega - \mathbf{y}\|_2^2 = (\mathbf{X}\omega - \mathbf{y})^T(\mathbf{X}\omega - \mathbf{y})$$

Аналитическое решение находится через приравнивание градиента к нулю:

$$\nabla_{\omega} Q(\omega) = 2\mathbf{X}^T\mathbf{X}\omega - 2\mathbf{X}^T\mathbf{y} = 0$$

Откуда получаем нормальное уравнение:

$$\omega = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

Условие существования

Решение существует и единственно, если матрица $\mathbf{X}^T\mathbf{X}$ невырождена (имеет полный ранг). Это эквивалентно линейной независимости признаков (отсутствию мультиколлинеарности).

2.3 Численные методы: QR-разложение

Прямое вычисление $(\mathbf{X}^T\mathbf{X})^{-1}$ вычислительно дорого $O(D^3)$ и неустойчиво. Метод **QR-разложения** позволяет решить задачу стабильнее:

1. Раскладываем $\mathbf{X} = \mathbf{Q}\mathbf{R}$, где $\mathbf{Q}$ — ортогональная матрица ($\mathbf{Q}^T\mathbf{Q} = \mathbf{I}$), а $\mathbf{R}$ — верхнетреугольная.
2. Подставляем в нормальное уравнение: $(\mathbf{R}^T\mathbf{Q}^T\mathbf{Q}\mathbf{R})\omega = \mathbf{R}^T\mathbf{Q}^T\mathbf{y}$.
3. Упрощаем: $\mathbf{R}^T\mathbf{R}\omega = \mathbf{R}^T\mathbf{Q}^T\mathbf{y} \implies \mathbf{R}\omega = \mathbf{Q}^T\mathbf{y}$.
4. Система с треугольной матрицей $\mathbf{R}$ решается методом обратной подстановки за $O(D^2)$.

2.4 Градиентный спуск (Gradient Descent)

Если аналитическое решение невозможно (огромные данные) или функция потерь неквадратична, используется итерационный подход:

$$\omega_{t+1} = \omega_t - \eta \nabla Q(\omega_t)$$

Где η — шаг обучения (*learning rate*). Для OLS шаг градиентного спуска выглядит так:

$$\omega_{t+1} = \omega_t - 2\eta\mathbf{X}^T(\mathbf{X}\omega_t - \mathbf{y})$$

Градиент направлен в сторону наискорейшего роста функции, поэтому мы вычитаем его, чтобы двигаться к минимуму.

3 Обработка категориальных признаков

Линейные модели требуют численного представления данных. Для работы с качественными переменными (город, профессия) применяется кодирование.

3.1 One-Hot Encoding (ОНЕ)

Метод заменяет один признак с M категориями на M новых бинарных столбцов.

- **Где можно использовать:**

- Категории не имеют естественного порядка (номинальные данные).
- *Пример:* Цвета автомобиля (красный, синий, зеленый), страны, типы почтовых отправлений.
- Линейные модели и нейросети — ОНЕ позволяет модели выучить независимый вес для каждой категории.

- **Где нельзя или не рекомендуется использовать:**

- **Высокая кардинальность:** Если у признака тысячи уникальных значений (напр., ID пользователя), ОНЕ создаст разреженную матрицу огромного размера, что приведет к переобучению и нехватке памяти.
- **Деревья решений:** ОНЕ "размывает" информацию. Дереву проще работать с порядковым кодированием (*Label Encoding*), так как оно может делать сплиты по группам категорий.
- **Порядковые данные:** Если категории имеют смысл "больше-меньше" (напр., размер одежды S, M, L), лучше использовать *Ordinal Encoding*, чтобы сохранить информацию о порядке.

Dummy Variable Trap

Для линейных моделей с интерсептом (w_0) необходимо удалять один столбец после ОНЕ ($M - 1$ признаков). В противном случае возникает строгая мультиколлинеарность, так как сумма всех ОНЕ-столбцов всегда равна единице.

4 Интерпретируемость моделей

Это способность модели объяснить, на основе каких признаков и почему было принято решение. По уровню прозрачности алгоритмы делятся на *White-box* (прозрачные) и *Black-box* (непрозрачные).

4.1 Линейные модели

Линейные модели относятся к наиболее интерпретируемым алгоритмам.

- **Веса ω_i :** Показывают вклад признака x_i . Если $\omega_i > 0$, рост признака увеличивает предсказание. Если $\omega_i < 0$ — уменьшает.
- **Абсолютное значение $|\omega_i|$:** Если признаки стандартизированы, то чем больше модуль веса, тем важнее признак для модели (*Feature Importance*).
- **Ограничение:** При наличии мультиколлинеарности веса теряют физический смысл и становятся неинтерпретируемыми.

4.2 Решающие деревья

Деревья интерпретируются через их структуру и правила принятия решений.

- **Путь от корня к листу:** Представляет собой цепочку логических условий (IF-THEN), понятных человеку без специальной подготовки.
- **Feature Importance:** Рассчитывается на основе того, насколько сильно каждый признак уменьшает неопределенность (энтропию или критерий Джини) во всех узлах дерева.
- *Ограничение:* Глубокие деревья («переобученные») становятся слишком сложными для визуального анализа человеком.

5 Свойства и ограничения линейных моделей

Понимание сильных и слабых сторон линейных алгоритмов необходимо для правильного выбора модели и качественной подготовки признаков.

5.1 Свойства

- **Простота и скорость:** Обучение и предсказание выполняются крайне быстро, что критично для высоконагруженных систем.
- **Интерпретируемость:** Прямая связь между признаками и целевой переменной через веса.
- **Работа с редкими данными:** Хорошо справляются с разреженными матрицами (sparse data) после ONE.

5.2 Ограничения

- **Линейность зависимости:** Модель не может выучить нелинейные паттерны и взаимодействия признаков (напр., $x_1 \cdot x_2$) без их явного добавления вручную (*Polynomial Features*).
- **Чувствительность к выбросам:** Квадратичная ошибка в МНК придает аномалиям слишком большой вес, что может "развернуть" разделяющую плоскость. Решение — использование Huber Loss или MAE.
- **Мультиколлинеарность:** При наличии сильно коррелирующих признаков веса становятся огромными и неустойчивыми. Требуется регуляризация.
- **Масштаб признаков:** Веса напрямую зависят от единиц измерения. Для корректной работы регуляризации и интерпретации обязательна нормализация.

6 Сведение обучения к задаче оптимизации

Процесс «обучения» модели в ML формализуется как поиск параметров, минимизирующих некоторую функцию ошибки на обучающей выборке.

6.1 Функция потерь и Функционал качества

Важно различать ошибку на одном объекте и на всей выборке:

- **Функция потерь** $L(a(x), y)$: Определяет величину ошибки на *одном* конкретном объекте x .
 - Для регрессии: $(a(x) - y)^2$ (квадратичная), $|a(x) - y|$ (абсолютная).
 - Для классификации: $\log(1 + \exp(-y \cdot a(x)))$ (логистическая).
- **Функционал качества** $Q(w)$: Суммарная ошибка на всей обучающей выборке X :

$$Q(w) = \frac{1}{N} \sum_{i=1}^N L(a(x_i, w), y_i)$$

Задача обучения — найти $w^* = \arg \min_w Q(w)$.

6.2 Stochastic Gradient Descent (SGD) и Mini-batches

Когда данных слишком много для вычисления градиента по всей выборке (Full Batch), используются стохастические методы:

1. **SGD**: На каждом шаге выбирается один случайный объект i , и веса обновляются по его градиенту: $w \leftarrow w - \eta \nabla L(x_i)$. Это очень быстро, но траектория обучения сильно "шумит".
2. **Mini-batch GD**: Золотая середина. Мы выбираем небольшое подмножество данных (*batch*) размера B (напр., 32, 64, 128) и вычисляем средний градиент по ним:

$$\nabla Q_{batch} = \frac{1}{B} \sum_{j=1}^B \nabla L(x_j)$$

Это позволяет эффективно использовать векторизацию вычислений на CPU/GPU и уменьшить шум по сравнению с чистым SGD.

7 Регуляризация и борьба с мультиколлинеарностью

7.1 Мультиколлинеарность

Это ситуация, когда признаки в матрице $\mathbf{X}$ сильно коррелируют друг с другом.

- **Последствия**: Матрица $\mathbf{X}^T \mathbf{X}$ становится близкой к вырожденной. Это приводит к неустойчивости оценок весов: малейшее изменение в данных вызывает гигантские скачки значений ω_i .
- **Решение**: Добавление штрафа за величину весов в функционал качества.

7.2 L2-регуляризация (Ridge Regression)

Добавляем квадрат $L2$ -нормы весов: $Q_{reg}(\omega) = Q(\omega) + \lambda \|\omega\|_2^2$.

- **Аналитическое решение**: $\omega = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$.
- **Плюсы**: Всегда делает матрицу обратимой, уменьшает дисперсию весов, имеет аналитическое решение.
- **Минусы**: Не зануляет веса (не делает отбор признаков).

7.3 L1-регуляризация (Lasso)

Добавляем $L1$ -норму весов: $Q_{reg}(\omega) = Q(\omega) + \lambda \|\omega\|_1$.

- **Особенность:** Из-за "острого" края ромба (линии уровня $L1$) точка оптимума часто попадает на оси координат.
- **Плюсы: Отбор признаков** (*Feature Selection*) — зануляет веса у неважных признаков.
- **Минусы:** Нет аналитического решения, нестабильна при сильной корреляции (выбирает один случайный признак из группы коррелирующих).

7.4 Сравнительная таблица

Свойство	L2 (Ridge)	L1 (Lasso)
Штраф	$\sum \omega_i^2$	$\sum \omega_i $
Решение	Аналитическое	Численное
Отбор признаков	Нет (веса малы, но $\neq 0$)	Да (зануляет лишнее)
Устойчивость	Высокая	Низкая (чувствительна к шуму)
Интерпретация	Сохраняет все признаки	Дает разреженную модель

8 Логистическая регрессия

8.1 Сигмоида (σ)

Для перевода выхода линейной модели $\omega^T x \in \mathbb{R}$ в вероятность $p \in [0, 1]$ используется логистическая функция (сигмоида):

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- **Свойство:** $\sigma'(z) = \sigma(z)(1 - \sigma(z))$, что удобно при расчете градиентов.
- **Смысл:** Она "сплюсчивает" бесконечную прямую в интервал $(0, 1)$, позволяя интерпретировать результат как уверенность модели.

8.2 Метод максимального правдоподобия (MLE)

Мы хотим подобрать такие ω , при которых наблюдаемые данные наиболее вероятны. Предположим, что $y_i \sim \text{Bernoulli}(p_i)$. Тогда правдоподобие всей выборки:

$$L(\omega) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$

Логарифмируя и меняя знак, переходим к минимизации **Log-Loss**:

$$Q(\omega) = -\frac{1}{n} \sum_{i=1}^n [y_i \ln(\sigma(\omega^T x_i)) + (1 - y_i) \ln(1 - \sigma(\omega^T x_i))]$$

8.3 Изменения пространства признаков

Линейные модели строят линейную разделяющую поверхность в текущем пространстве признаков. Чтобы выучить нелинейные зависимости, мы можем трансформировать исходное пространство:

- **Полиномиальные признаки:** Добавление степеней и произведений признаков ($x_1, x_2 \rightarrow x_1^2, x_1x_2, x_2^2$). Это позволяет модели строить криволинейные границы (эллипсы, параболы).
- **RBF и Ядра:** Переход в бесконечномерное пространство, где данные становятся линейно separable (основа SVM с ядрами).
- **Feature Engineering:** Ручное создание признаков (напр., $\sin(x)$, $\text{sign}(x)$) на основе знаний о предметной области.

9 Функции потерь классификации

Для задач классификации с метками $y \in \{-1, 1\}$ часто используют функции от *отступа* (margin) $M = y \cdot (\omega^T x)$.

9.1 Perceptron Loss

$$L(M) = \max(0, -M)$$

- Ошибкой считаются только те объекты, которые лежат на «чужой» стороне разделяющей плоскости.
- Не дает никакой уверенности в классификации — объект может быть очень близко к границе.

9.2 Hinge Loss и SVM

$$L(M) = \max(0, 1 - M)$$

Это стандартная функция потерь для **SVM (Метод опорных векторов)**.

- **Зазор (Margin):** В отличие от перцептрона, Hinge Loss требует, чтобы объекты не просто были классифицированы верно ($M > 0$), но и находились на расстоянии хотя бы 1 от разделяющей прямой ($M \geq 1$).
- Все объекты с $M < 1$ вносят вклад в ошибку. Это обеспечивает «максимальный разделяющий зазор», что делает модель более устойчивой к шуму.

10 Kernel Trick и ядерные методы

Ядерный переход (*Kernel Trick*) позволяет линейным моделям работать в нелинейных пространствах без явного вычисления координат новых признаков.

10.1 Суть метода

Многие алгоритмы (SVM, PCA, Линейная регрессия) зависят только от скалярных произведений объектов $\langle x_i, x_j \rangle$. Мы можем заменить их на **ядерную функцию** $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$, которая вычисляет скалярное произведение в некотором пространстве более высокой размерности $\phi(\cdot)$.

10.2 Виды ядер

- **Линейное (Linear):** $K(x, y) = x^T y$. Обычное скалярное произведение. Используется, когда данных много или они уже линейно разделимы.
- **Полиномиальное (Polynomial):** $K(x, y) = (x^T y + c)^d$. Позволяет учитывать взаимодействия признаков до степени d .
- **RBF / Гауссово (Radial Basis Function):** $K(x, y) = \exp(-\gamma \|x - y\|^2)$. Бесконечномерное ядро. Самое популярное для нелинейных задач. γ определяет "радиус влияния" каждого объекта.
- **Сигмоидальное (Sigmoid):** $K(x, y) = \tanh(\alpha x^T y + c)$. Позволяет имитировать поведение двухслойной нейронной сети.

10.3 Kernel Density Estimation (KDE)

Ядерная оценка плотности — это непараметрический способ оценки функции распределения случайной величины.

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

- Вместо грубых "ящиков" гистограммы мы ставим "колокол" ядра (обычно Гауссова) над каждой точкой данных.
- Параметр *bandwidth* (h) контролирует гладкость: слишком малое h дает шум, слишком большое — переглаженное распределение.

11 Многоклассовая классификация

Когда число классов $K > 2$, бинарная логистическая регрессия обобщается до многоклассовой (Multinomial Logistic Regression).

11.1 Вероятности и Softmax

Вместо одного числа модель выдает вектор "сырых" ответов (*logits*) $z = (z_1, \dots, z_K)$. Чтобы превратить их в вероятности, используется функция **Softmax**:

$$P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

- Сумма всех вероятностей всегда равна 1.
- Каждый компонент $P \in (0, 1)$.
- Softmax является многомерным обобщением сигмоиды.

11.2 Функция потерь: Cross-Entropy

Для многоклассовой классификации минимизируется кросс-энтропия между истинным распределением (One-Hot вектор y) и предсказанным (p):

$$Q(\omega) = - \sum_{i=1}^n \sum_{k=1}^K y_{ik} \ln p_{ik}$$

Если объект относится к классу k , то $y_{ik} = 1$, и мы просто минимизируем $-\ln p_{ik}$ (максимизируем вероятность правильного класса).

11.3 Алгоритмы сведения к бинарным задачам

Если мы не хотим использовать Softmax напрямую, можно применить стратегии:

- **One-vs-Rest (OvR)**: Обучаем K классификаторов. Каждый учится отличать свой класс от всех остальных вместе взятых. Предсказание — класс с максимальной уверенностью.
- **One-vs-One (OvO)**: Обучаем $K(K-1)/2$ классификаторов для каждой пары классов. Итоговое решение принимается голосованием большинства. Более устойчива к дисбалансу, но требует много моделей.

12 Деер Q&A: Вопросы и подробные ответы

Q1: Почему в Ridge-регрессии веса никогда не становятся ровно нулями?

Ответ: Линии уровня L2-штрафа — это сферы. Касание линий уровня функции потерь и сферы может произойти в любой точке. Вероятность того, что точка касания попадет точно на координатную ось в высокоразмерном пространстве, практически нулевая. В отличие от L1 (ромб), у L2 нет "углов" на осях.

Q2: Как мультиколлинеарность влияет на дисперсию весов?

Ответ: Дисперсия весов обратно пропорциональна определителю $\mathbf{X}^T \mathbf{X}$. При мультиколлинеарности матрица близка к вырожденной, её определитель мал, что раздувает дисперсию оценок весов. Это делает модель крайне чувствительной к малейшим изменениям в обучающей выборке.

Q3: В чем разница между моделями One-vs-Rest и One-vs-One?

Ответ:

- **OvR:** Обучаем K классификаторов ("Класс i против всех остальных"). Быстрее, но может возникнуть дисбаланс классов.
- **OvO:** Обучаем $K(K-1)/2$ классификаторов для каждой пары. Более устойчива к дисбалансу, но вычислительно дороже при большом числе классов.

Q4: Зачем нужна калибровка вероятностей (напр. по Платту)?

Ответ: Некоторые модели (например, SVM) не выдают вероятности напрямую. Сигмоидальная калибровка Платта обучает логистическую регрессию над выходами модели, чтобы превратить их в честные доверительные интервалы $[0, 1]$.

Q5: Что такое Rank Deficiency и как его лечить?

Ответ: Это ситуация, когда число признаков D больше числа объектов N , либо признаки линейно зависимы. В этом случае $\mathbf{X}^T \mathbf{X}$ необратима. Лечится добавлением L2-регуляризации, которая делает матрицу $(\mathbf{X}^T \mathbf{X} + \lambda I)$ строго положительно определенной и всегда обратимой.

Antigravity: Этот уровень проработки теории отличает Senior ML-инженера от новичка. Помните: любая сложная нейросеть — это всего лишь композиция простых линейных преобразований и нелинейностей.