

Глубокий разбор: Линейные модели в машинном обучении

Твой персональный гид по ML

4 мая 2026 г.

Введение

Привет! Как твой персональный гид по миру матриц и градиентов, я подготовил для тебя подробный разбор основ машинного обучения. Давай пройдемся по твоим вопросам, опираясь на предоставленные материалы.

Содержание

1	Типология задач машинного обучения	2
2	Математический аппарат и обозначения	2
3	Обработка категориальных признаков	2
4	Интерпретируемость моделей	2
5	Свойства и ограничения линейных моделей	2
6	Сведение обучения к задаче оптимизации	3
7	Мультиколлинеарность и регуляризация	3
8	Сравнение L1 и L2 регуляризаций	3
9	Функция потерь перцептрона	3
10	Hinge Loss и SVM	3
11	Логистическая регрессия и вероятности	3
12	Анализ гиперпараметров регуляризации	3
13	Softmax для многоклассовой классификации	3

1 Типология задач машинного обучения

В обучении с учителем выделяют следующие задачи:

- **Регрессия:** целевая переменная принимает вещественные значения ($Y = \mathbb{R}$).
- **Бинарная классификация:** выбор из двух классов, обычно $\{0, 1\}$ или $\{-1, 1\}$.
- **Многоклассовая классификация:** выбор одного из K классов.
- **Многоклассовая классификация multilabel:** объект может принадлежать нескольким классам одновременно ($Y = \{0, 1\}^K$).
- **Ранжирование:** необходимо отсортировать объекты по их релевантности.

Главное отличие в природе таргетов. В регрессии мы предсказываем число, в классификации — метку класса.

2 Математический аппарат и обозначения

- **Матрица X :** матрица «объекты — признаки» размера $N \times D$.
- **Вектор y :** истинные ответы для всех объектов.
- **Вектор весов w :** параметры модели. Он определяет вклад каждого признака в предсказание: $y = \langle x, w \rangle + w_0$.

3 Обработка категориальных признаков

One-hot-кодирование заменяет категориальный признак с M значениями на M новых бинарных признаков.

Почему нельзя (1, 2, 3): Линейная модель воспринимает эти числа как шкалу. Она решит, что категория «3» в три раза больше «1», что бессмысленно для профессий или городов.

4 Интерпретируемость моделей

Это способность модели объяснить, на основании чего сделано предсказание.

- **Линейные модели:** через веса w_i . Большой положительный вес — признак сильно увеличивает результат.
- **Решающие деревья:** через структуру узлов — путь от корня к листу.

5 Свойства и ограничения линейных моделей

- **Узкий класс:** описывают только линейные зависимости. Требуют *feature engineering*.
- **Мультиколлинеарность:** зависимость признаков ведет к огромным и неустойчивым весам.
- **Масштаб:** признаки должны быть отнормированы для правильной интерпретации весов.

6 Сведение обучения к задаче оптимизации

- **Функция потерь (Loss):** ошибка на одном объекте.
- **Функционал качества:** средняя ошибка по выборке (Эмпирический риск).
- **Оптимизация:** поиск весов w , минимизирующих функционал.

7 Мультиколлинearность и регуляризация

Регуляризация добавляет штраф за сложность: $\min(Loss + \lambda \|w\|)$. Коэффициент λ контролирует баланс между ошибкой и величиной весов.

8 Сравнение L1 и L2 регуляризаций

- L_2 (**Ridge**): $\lambda \sum w_i^2$. Делает веса маленькими, устойчива к шуму.
- L_1 (**Lasso**): $\lambda \sum |w_i|$. Обнуляет веса неважных признаков (разреживание).

9 Функция потерь перцептрона

$F(M) = \max(0, -M)$, где $M = y_i \langle w, x_i \rangle$ — отступ. Ошибка растет, если отступ отрицательный.

10 Hinge Loss и SVM

$H(M) = \max(0, 1 - M)$. Заставляет модель максимизировать **зазор** (margin). Опорные векторы лежат на границе этого зазора.

11 Логистическая регрессия и вероятности

Перевод логита $\langle w, x \rangle$ в вероятность через сигмоиду: $\sigma(z) = \frac{1}{1+e^{-z}}$.

12 Анализ гиперпараметров регуляризации

- **Большой λ :** веса стремятся к нулю (недообучение).
- **Маленький λ :** сложная граница, подстройка под выбросы (переобучение).

13 Softmax для многоклассовой классификации

$P(y = k|x) = \frac{e^{z_k}}{\sum e^{z_j}}$. Гарантирует, что сумма вероятностей всех классов равна 1.

Antigravity: Линейные модели — это фундамент. Правильно настроенная регуляризация и грамотный фича-инжиниринг делают их мощным инструментом даже в эпоху глубокого обучения.